HỌC VIỆN
CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG
Posts and Telecommunications Institute of Technology

Nghiên cứu và xây dựng mô hình học máy phát hiện bất thường dựa trên nhật ký hệ thống

Thành viên nhóm 03
Nguyễn Huy Hoàng - B23DCAT112
Đỗ Trung Kiên - B23DCAT156
Hà Duy Long - B23DCAT172

NỘI DUNG

01 Tổng quan về phát hiện bất thường từ nhật ký hệ thống và các phương pháp phát hiện

02 Đề xuất mô hình phát hiện bất thường từ nhật ký hệ thống

03 Thực nghiệm và đánh giá

Phần 1

Tổng quan về phát hiện bất thường từ nhật ký hệ thống và các phương pháp phát hiện

Tổng quan về phát hiện bất thường từ nhật ký hệ thống và các phương pháp phát hiện

Chương 1 trình bày cơ sở lý thuyết về phát hiện bất thường từ nhật ký hệ thống và các phương pháp phát hiện phổ biến:

- Tổng quan về phát hiện bất thường từ nhật ký hệ thống
- Các phương pháp phát hiện bất thường từ nhật ký hệ thống
- Một số nghiên cứu liên quan về phát hiện bất thường từ nhật ký hệ thống
- Kết chương

Tổng quan về phát hiện bất thường từ nhật ký hệ thống

- **Tổng quan về nhật ký hệ thống và phát hiện bất thường**
- **Quy trình xử lý và thách thức của bài toán**

Tổng quan về phát hiện bất thường từ nhật ký hệ thống

Tổng quan về nhật ký hệ thống và phát hiện bất thường

- Nhật ký hệ thống là tập hợp các bản ghi được sinh ra trong quá trình thực thi của phần mềm, hệ điều hành, máy chủ hoặc các dịch vụ mạng.
- Log là nguồn dữ liệu quan trọng để giám sát hệ thống, chẩn đoán sự cố, phát hiện lỗi phần mềm, lỗi cấu hình, tấn công, quá tải tài nguyên và các hành vi bất thường.
- Phát hiện bất thường từ log là quá trình xác định những mẫu log, chuỗi log hoặc phiên hoạt động có sự khác biệt đáng kể so với hành vi vận hành bình thường.

Tổng quan về phát hiện bất thường từ nhật ký hệ thống

Quy trình xử lý và thách thức của bài toán

- Quy trình bài toán: log thô -> tiền xử lý/chuẩn hóa -> ánh xạ thành sự kiện có cấu trúc -> gom theo phiên/cửa sổ thời gian -> trích xuất vector đặc trưng -> mô hình phân loại bình thường/bất thường.
- Khó khăn chính: log không đồng nhất, chứa nhiều trường động, dữ liệu bất thường khan hiếm và mất cân bằng lớp; thêm vào đó khối lượng log rất lớn khiến phân tích thủ công kém hiệu quả.
- Vì vậy, cần các phương pháp phát hiện tự động có khả năng học mẫu vận hành thực tế để giảm cảnh báo giả và hỗ trợ phát hiện chính xác hơn.

Các phương pháp phát hiện bất thường từ nhật ký hệ thống

- Phương pháp dựa trên luật và dấu hiệu
- Phương pháp dựa trên thống kê và khai phá mẫu
- Phương pháp học máy có giám sát
- Phương pháp học máy không giám sát
- Phương pháp học sâu

Các phương pháp phát hiện bất thường từ nhật ký hệ thống

Phương pháp dựa trên luật, dấu hiệu và thống kê

- Dựa trên luật và dấu hiệu
  - Xây dựng luật thủ công, tìm từ khóa lỗi, mẫu câu nguy hiểm
  - Ưu điểm: đơn giản, dễ áp dụng, tốt với lỗi đã biết
  - Nhược điểm: phụ thuộc chuyên gia, khó phát hiện bất thường mới
- Dựa trên thống kê và khai phá mẫu
  - Phát hiện sai khác so với phân bố bình thường
  - Kỹ thuật tiêu biểu: PCA, khai phá quan hệ bất biến, phân cụm
  - Phù hợp khi muốn khai thác quy luật vận hành chung của hệ thống

Các phương pháp phát hiện bất thường từ nhật ký hệ thống

Phương pháp học máy có giám sát

- Cần dữ liệu đã gán nhãn bình thường/bất thường
- Một số mô hình tiêu biểu:
  - Logistic Regression: đơn giản, nhanh, dễ triển khai
  - Decision Tree: trực quan, dễ giải thích
  - SVM: phân tách dữ liệu tốt trong không gian nhiều chiều
- Hạn chế:
  - Phụ thuộc vào chất lượng nhãn
  - Cần tập huấn luyện đủ tốt

Các phương pháp phát hiện bất thường từ nhật ký hệ thống

Phương pháp học máy không giám sát

- Không cần dữ liệu gán nhãn
- Các hướng tiêu biểu:
  - Log Clustering: gom các mẫu log tương tự thành cụm
  - PCA: phát hiện bất thường qua phần sai khác ngoài không gian chính
  - Invariant Mining: tìm quan hệ ổn định giữa các sự kiện log
- Ưu điểm:
  - Phù hợp thực tế khi nhãn khan hiếm
- Hạn chế:
  - Có thể khó diễn giải hoặc phụ thuộc ngưỡng

Các phương pháp phát hiện bất thường từ nhật ký hệ thống

Học sâu và so sánh các phương pháp

- Học sâu
  - Mô hình tiêu biểu: DeepLog, LogAnomaly
  - Ưu điểm: học tốt ngữ cảnh chuỗi log, mô hình hóa quan hệ phức tạp
  - Nhược điểm: chi phí tính toán cao, cần nhiều dữ liệu, khó diễn giải
- Kết luận so sánh
  - Không có phương pháp nào tối ưu cho mọi trường hợp
  - Việc lựa chọn phụ thuộc vào:
    - Đặc điểm dữ liệu log
    - Khả năng có nhãn hay không
    - Tài nguyên tính toán
    - Yêu cầu giải thích kết quả

Một số nghiên cứu liên quan về phát hiện bất thường từ nhật ký hệ thống

- Xu hướng nghiên cứu mới là khai thác ngữ nghĩa sâu của log thay cho chỉ dùng đặc trưng đếm sự kiện.
- Các mô hình như LAnoBERT, CLDTLog cho kết quả rất cao trên HDFS, BGL.
- MetaLog cho thấy tiềm năng phát hiện xuyên hệ thống khi dữ liệu nhãn ít.
- LogCraft hướng tới tự động hóa toàn bộ quy trình phát hiện bất thường.
- Kết luận: hiệu quả cuối cùng vẫn phụ thuộc vào dữ liệu, tiền xử lý, biểu diễn đặc trưng và bối cảnh triển khai.

Phần 2

Đề xuất mô hình phát hiện bất thường từ nhật ký hệ thống

Đề xuất mô hình phát hiện bất thường từ nhật ký hệ thống

- Phát biểu bài toán
- Mô hình lựa chọn
- Kiến trúc đề xuất
- Quy trình xử lý và phát hiện bất thường

Đề xuất mô hình phát hiện bất thường từ nhật ký hệ thống

Phát biểu bài toán

- Bài toán: tự động phân biệt phiên log bình thường và phiên log bất thường
- Dữ liệu sử dụng là log HDFS, trong đó mỗi phiên được xác định theo block_id.
- Mục tiêu là học được quy luật vận hành để dự đoán có bất thường hay không.

Đề xuất mô hình phát hiện bất thường từ nhật ký hệ thống

Input

- Log HDFS thô: thời gian, nội dung log, block_id, tham số động
- Sau tiền xử lý: log được gom theo session và biểu diễn thành ma trận đặc trưng X
- Mỗi phiên log tương ứng với một event count vector
- Input trực tiếp của mô hình: (X, y) với y là vector nhãn

Output

- Nhãn dự đoán cho mỗi phiên log:
  - 0: normal
  - 1: anomaly

Đề xuất mô hình phát hiện bất thường từ nhật ký hệ thống

Cơ sở lựa chọn mô hình

- Xem xét 3 mô hình: LR, SVM, Decision Tree
- Chọn Decision Tree vì:
  - Hiệu quả tốt trên HDFS
  - Dễ triển khai
  - Dễ giải thích kết quả
- Các mô hình còn lại dùng để so sánh

Đề xuất mô hình phát hiện bất thường từ nhật ký hệ thống

Kiến trúc tổng thể

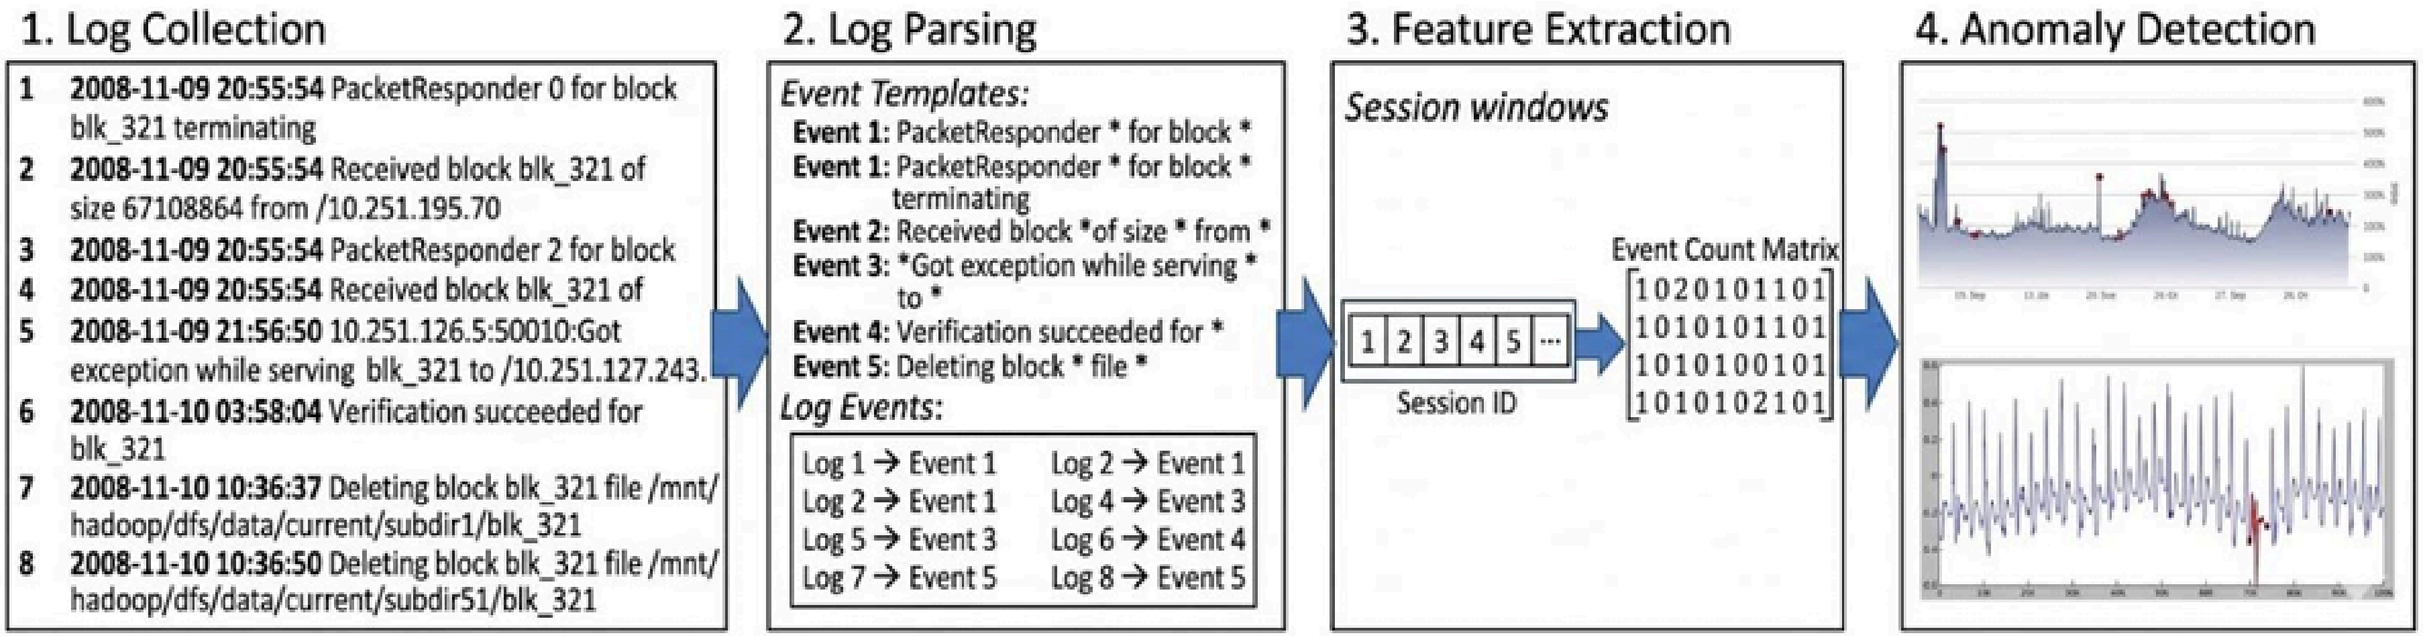

Đề xuất mô hình phát hiện bất thường từ nhật ký hệ thống

Log thô

Ban đầu hệ thống có các dòng log như sau:

- *10:01 blk_101 Received block from node A*
- *10:02 blk_101 Received block from node B*
- *10:03 blk_101 Verification succeeded*
- *10:04 blk_101 Deleted block*

Đề xuất mô hình phát hiện bất thường từ nhật ký hệ thống

Log parsing

Sau khi chuẩn hóa, mỗi dòng log được đưa về mẫu sự kiện:

- *Received block from node A* → ***E1: Received block***
- *Received block from node B* → ***E1: Received block***
- *Verification succeeded* → ***E2: Verification success***
- *Deleted block* → ***E3: Delete block***

Đề xuất mô hình phát hiện bất thường từ nhật ký hệ thống

Gom nhóm theo session window

Vì các log trên cùng có **block_id = blk_101**, nên chúng được gom thành 1 session

Session S1 = ***[E1, E1, E2, E3]***

Đề xuất mô hình phát hiện bất thường từ nhật ký hệ thống

Trích xuất đặc trưng

Giả sử toàn bộ hệ thống có 5 loại sự kiện:

- E1: Received block
- E2: Verification success
- E3: Delete block
- E4: Error
- E5: Timeout

Khi đó **session S1 = [E1, E1, E2, E3]** sẽ được biểu diễn thành: **Vector S1 = [2, 1, 1, 0, 0]**

Giải thích:

- E1 xuất hiện 2 lần
- E2 xuất hiện 1 lần
- E3 xuất hiện 1 lần
- E4, E5 không xuất hiện

→ **Event count vector**

Đề xuất mô hình phát hiện bất thường từ nhật ký hệ thống

Đưa vào mô hình phát hiện

Vector đặc trưng sẽ được đưa vào mô hình:

- Nếu mẫu giống hành vi bình thường → Normal (0)
- Nếu mẫu có phân bố sự kiện bất thường → Anomaly (1)

Ví dụ:

- **S1 = [2,1,1,0,0]** → có thể được dự đoán là **bình thường**
- **S2 = [0,0,1,3,2]** → có nhiều *lỗi/timeout* → có thể được dự đoán là **bất thường**

Đề xuất mô hình phát hiện bất thường từ nhật ký hệ thống

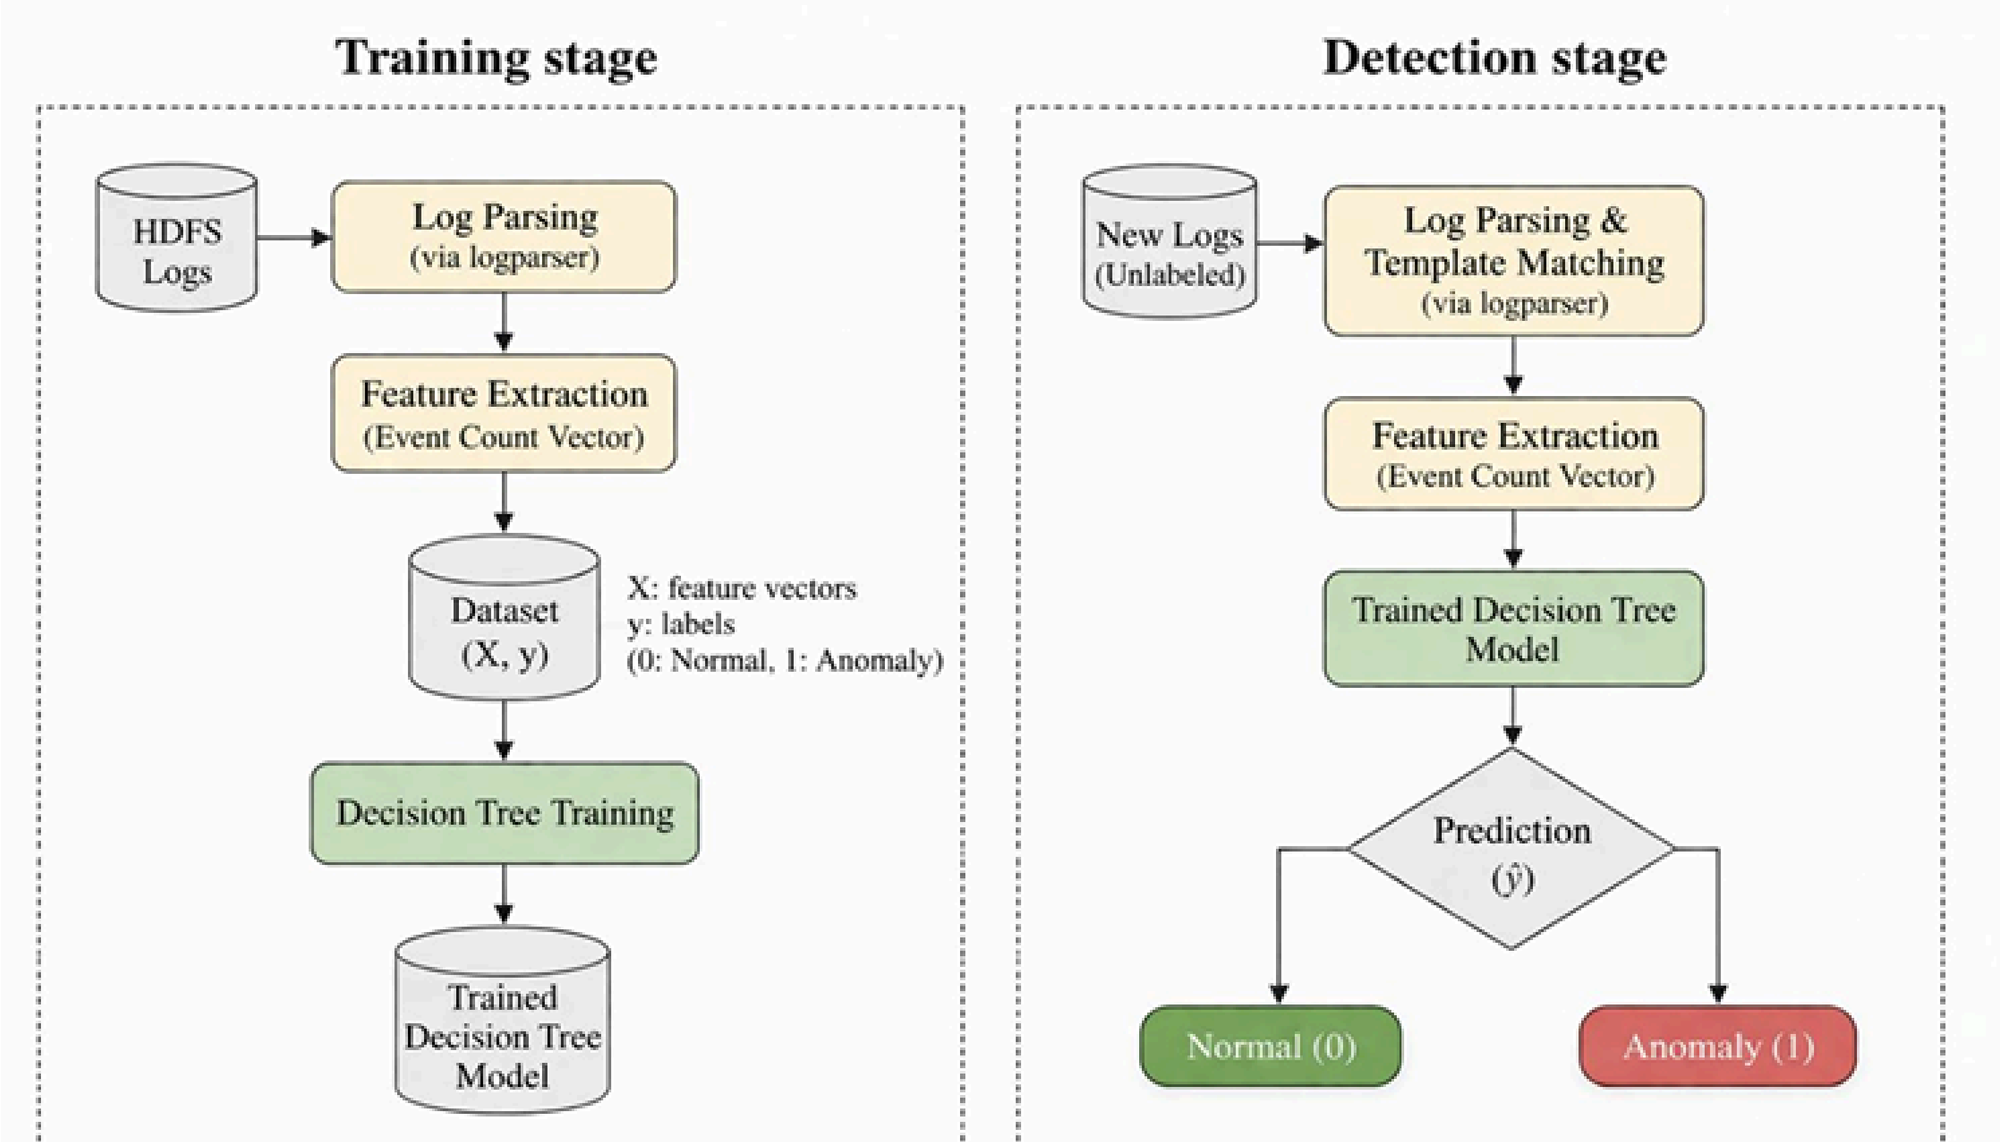

Phần 3

Thực nghiệm và đánh giá

Mục tiêu thực nghiệm

- Kiểm tra tính hiệu quả của mô hình Decision Tree.
- So sánh với các phương pháp học máy có giám sát khác là Logistic Regression và SVM, và các phương pháp học máy không giám sát là Log Clustering, Invariant Mining và PCA nhằm làm rõ vị trí và hiệu quả của từng mô hình cho bài toán.

Bộ dữ liệu và thiết lập thực nghiệm

- Dữ liệu log HDFS được thu thập từ nền tảng Amazon EC2, có thời gian ghi nhận 38.7 giờ, dung lượng khoảng 1.55GB, chứa tổng cộng 11.175.629 thông điệp log.
- Dữ liệu sẽ được chia làm 2 phần, 80% cho huấn luyện và 20% cho kiểm thử.
- Các chỉ số đánh giá được sử dụng gồm Precision, Recall và F1-score.
- HDFS được chọn vì:
  - 1 block_id liên quan đến 1 thao tác => dễ gom nhóm theo session.
  - Có 29 loại sự kiện, ít hơn nhiều so với các loại log khác.
  - Log khi được gom theo block_id thì mức tương quan giữa các sự kiện trong chuỗi log tăng lên đáng kể.

Các độ đo đánh giá

- Sử dụng các chỉ số Precision, Recall và F1- score.
  - Precision phản ánh tỷ lệ các phiên được dự đoán là bất thường mà thực sự bất thường.
  - Recall phản ánh tỷ lệ các phiên bất thường thực sự được mô hình phát hiện.
  - F1-score là trung bình điều hòa giữa Precision và Recall, dùng để đánh giá tổng hợp hiệu quả của mô hình.

Kết quả của các mô hình có giám sát

- **Kết quả trên tập huấn luyện**

Mô hình	Precision (%)	Recall (%)	F1-score (%)
LR	86.43	71.05	77.99
SVM	96.07	97.18	96.62
Decision Tree	99.84	99.96	99.90

- **Kết quả trên tập kiểm thử**

Mô hình	Precision (%)	Recall (%)	F1-score (%)
LR	86.36	72.00	78.53
SVM	96.01	97.12	96.56
Decision Tree	99.79	99.88	99.84

Kết quả của các mô hình có giám sát

Từ các kết quả trên, có thể thấy rằng nhóm mô hình có giám sát nhìn chung đạt độ chính xác cao do tận dụng được thông tin nhãn trong quá trình huấn luyện. Trong đó, Decision Tree là mô hình nổi bật nhất nhờ đạt sự cân bằng rất tốt giữa Precision và Recall, qua đó nâng cao hiệu quả phát hiện bất thường mà không làm gia tăng đáng kể số lượng cảnh báo sai. Kết quả này cho thấy các phương pháp có giám sát là lựa chọn phù hợp khi bộ dữ liệu huấn luyện có sẵn nhãn đầy đủ và đáng tin cậy.

Kết quả của các mô hình không giám sát

- **Kết quả trên tập huấn luyện**

Mô hình	Precision (%)	Recall (%)	F1-score (%)
PCA	97.50	63.46	76.88
InvariantsMiner	89.44	100	94.42
LogClustering	100	71.96	83.69
Isolation Forest	79.22	79.02	79.12

- **Kết quả trên tập kiểm thử**

Mô hình	Precision (%)	Recall (%)	F1-score (%)
PCA	97.35	64.40	77.52
InvariantsMiner	89.94	100	94.14
LogClustering	100	72.03	83.74
Isolation Forest	78.19	79.51	78.85

Kết quả của các mô hình không giám sát

So với nhóm mô hình có giám sát, hiệu năng của các phương pháp không giám sát thường thấp hơn do không tận dụng trực tiếp được thông tin nhãn trong giai đoạn huấn luyện. Tuy nhiên, ưu điểm của nhóm này là có khả năng áp dụng linh hoạt trong các hệ thống thực tế, nơi dữ liệu bất thường hiếm và khó gán nhãn. Vì vậy, mặc dù kết quả có thể chưa đạt mức cao như các mô hình có giám sát, nhóm phương pháp này vẫn có giá trị lớn trong các kịch bản triển khai thực tế.

So sánh thời gian xử lý của các mô hình

Bảng so sánh thời gian xử lý của các mô hình

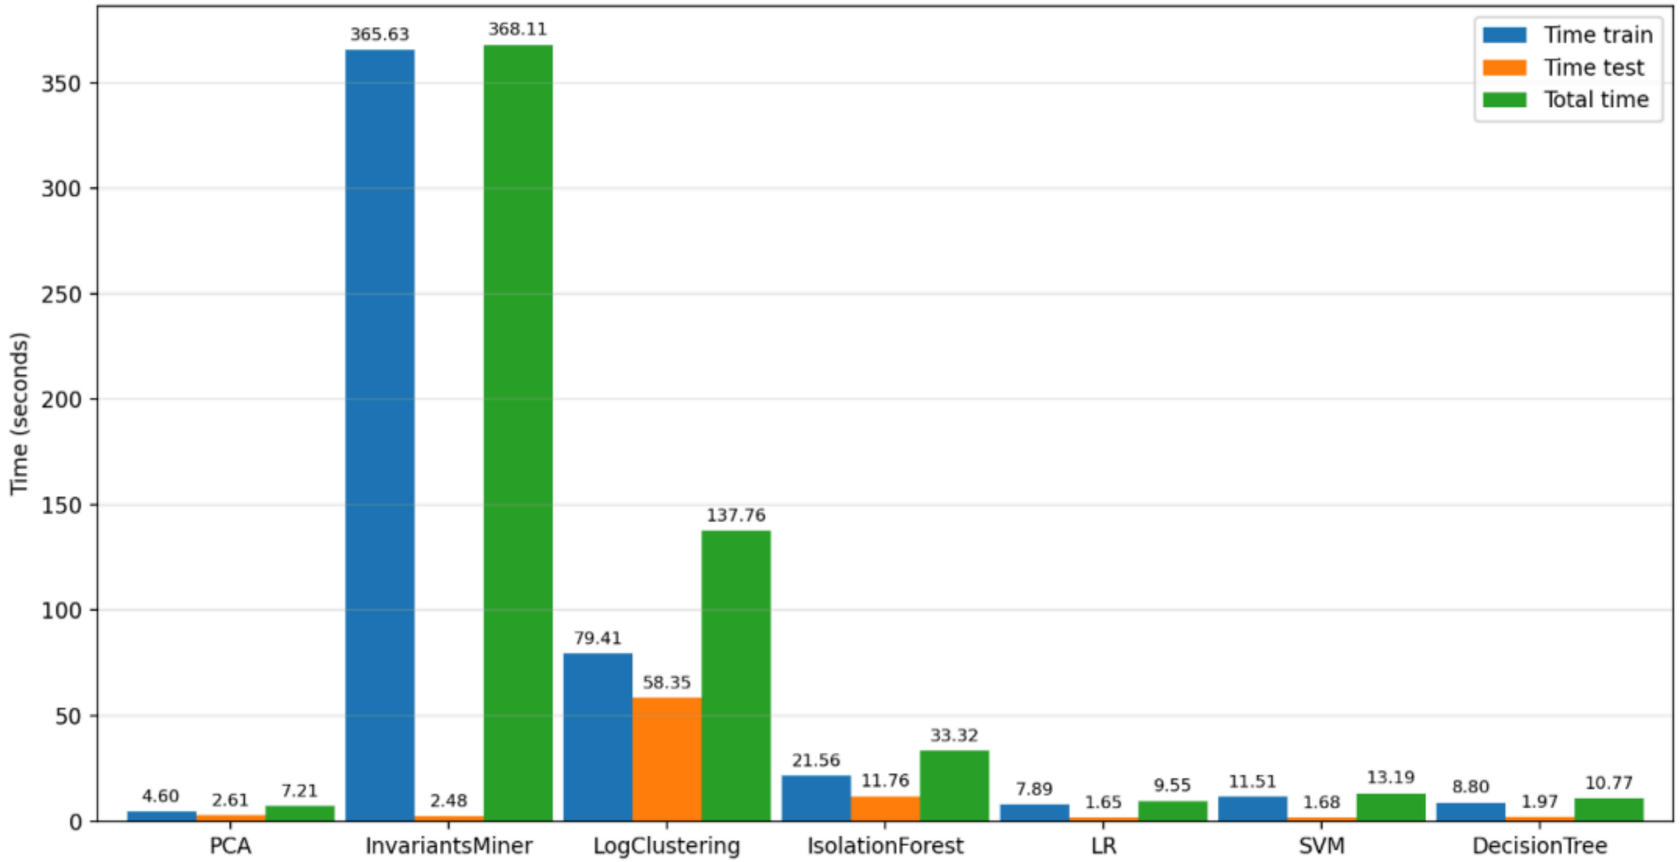

Đánh giá khả năng mở rộng của các mô hình theo quy mô dữ liệu

Để đánh giá khả năng mở rộng của các mô hình, báo cáo khảo sát sự thay đổi của hiệu năng và thời gian xử lý khi quy mô dữ liệu đầu vào tăng dần theo các mức 1%, 5%, 10%, 25%, 50% và 100% của toàn bộ tập dữ liệu.

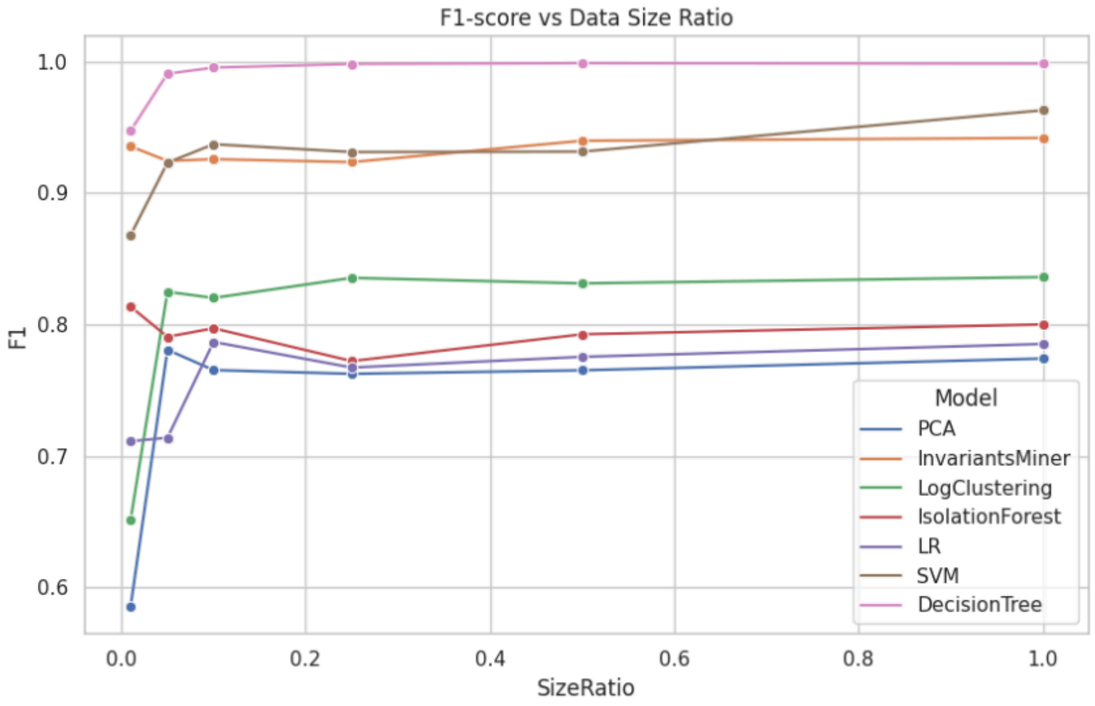

Đánh giá khả năng mở rộng của các mô hình theo quy mô dữ liệu

Bên cạnh hiệu năng phát hiện, hình dưới trình bày tổng thời gian xử lý của các mô hình theo từng mốc dữ liệu

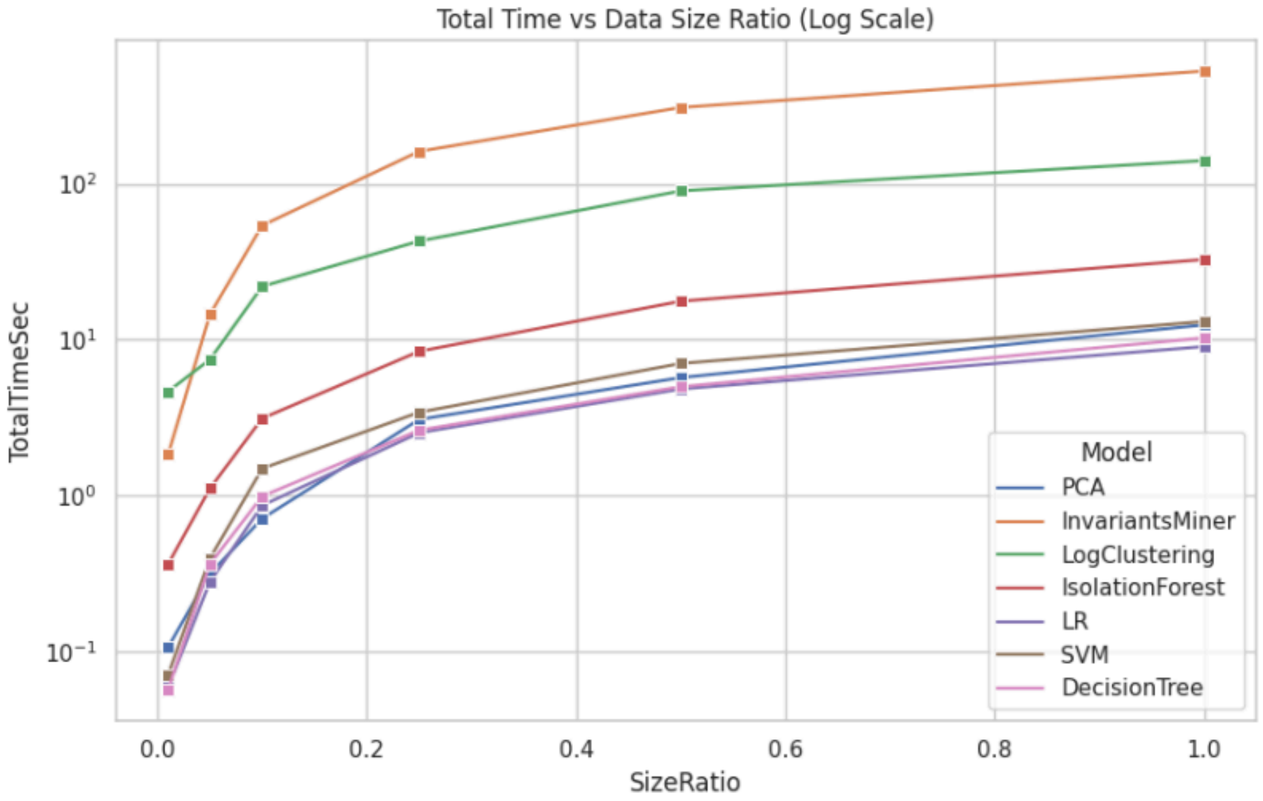

Đánh giá và nhận xét

- Từ các kết quả thực nghiệm có thể thấy rằng các mô hình có giám sát cho hiệu quả phát hiện bất thường tốt hơn so với nhóm mô hình không giám sát.
- Trong nhóm có giám sát, Decision Tree là mô hình đạt kết quả cao nhất trên tập kiểm thử. Điều này cho thấy với dữ liệu log đã có nhãn, các mô hình phân loại có khả năng học ranh giới quyết định tốt sẽ cho hiệu năng cao hơn.

Đánh giá và nhận xét

- Đối với nhóm mô hình không giám sát, Invariants Miner là phương pháp đạt kết quả nổi bật nhất. Tuy vậy, nhóm mô hình này vẫn có ý nghĩa thực tiễn trong các trường hợp dữ liệu thiếu nhãn hoặc khó gán nhãn.
- Về thời gian xử lý, Decision Tree là phương pháp đạt sự cân bằng tốt nhất giữa độ chính xác và chi phí tính toán.
- Khi đánh giá theo quy mô dữ liệu, Decision Tree tiếp tục cho thấy ưu thế rõ rệt khi vừa 30 duy trì F1-score cao, vừa có thời gian xử lý tăng theo xu hướng ổn định.

Cảm ơn mọi người đã chú ý lắng nghe!